

Elegir la métrica adecuada para tu problema

Contexto:

En Machine Learning no hay una única métrica que funcione para todos los casos. Elegir la métrica correcta según el tipo de problema (regresión o clasificación) y su contexto es clave para una buena evaluación.

Consigna:

Analiza diferentes escenarios de aplicación de modelos (salud, e-commerce, finanzas, etc.) y decide qué métrica usarías para evaluar el modelo, justificando tu elección.

Paso a paso:

1. Revisa los 4 casos de aplicación que te entregará el docente (por ejemplo: detección de fraude, predicción de precios, diagnóstico médico, recomendación de productos).
2. Clasifica cada problema como regresión o clasificación.
3. Elige al menos dos métricas adecuadas para evaluar el modelo.
4. Justifica tu elección considerando el costo de errores (falsos positivos/negativos, errores grandes vs pequeños, etc).
5. Comparte las decisiones.

Actividad: Elegir la métrica adecuada para tu problema

Caso 1: Mantenimiento predictivo en fábricas

Una empresa de manufactura quiere anticipar fallas en sus máquinas. Cada equipo tiene sensores que registran temperatura, vibraciones y horas de uso. Se busca predecir la vida útil restante (en horas).

Caso 2: Clasificación de reseñas de clientes

En un e-commerce se quiere clasificar automáticamente las reseñas de clientes en positivo, neutral o negativo para agilizar el análisis de satisfacción.

Caso 3: Detección de intrusiones en ciberseguridad

Un sistema de seguridad informática recibe millones de conexiones diarias. Se busca identificar si cada conexión es legítima o un ataque.

Caso 4: Predicción de consumo energético en hogares inteligentes

Una empresa eléctrica quiere predecir el consumo energético de los hogares en las próximas horas para optimizar la red y reducir costos.

Caso de Aplicación	¿Es clasificación o regresión?	Posibles métricas (elige al menos 2)	¿Cuál elegirías y porqué?(justificación del error más costoso)
Ejemplo: Predicción de demanda de transporte público en una ciudad	Regresión	MAE, RMSE, MAPE	MAPE, porque permite entender el error de porcentaje respecto a la demanda real. Es clave ya que un error del 10% en horas punta implica sobrecarga o déficit de buses, lo cual afecta directamente a la población.
Mantenimiento predictivo en fábricas	Regresión	MAE, RMSE	RMSE, porque errores grandes en la predicción de la vida útil pueden provocar fallas inesperadas y costosas en las máquinas, mientras que un error pequeño es menos crítico.
Clasificación de reseñas de clientes	Clasificación	Accuracy, F1-Score	F1-Score, ya que clasificar incorrectamente reseñas negativas puede afectar la percepción del cliente y la toma de decisiones, por lo que es importante balancear precisión y recall.
Detección de intrusiones en ciberseguridad	Clasificación	Recall, F1-Score	Recall, porque pasar por alto un ataque es mucho más costoso que bloquear algunas conexiones legítimas; priorizar la detección de intrusiones es clave.
Predicción de consumo energético en hogares inteligentes	Regresión	MAE, RMSE	RMSE, porque errores grandes en la predicción del consumo energético pueden causar sobrecargas o subutilización de la red, generando pérdidas económicas y operativas.